```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy.stats import skew
```

```
df = pd.read_csv('vacancies.csv',sep=',')
df.head(20)
```

	vacancy_id	salary_from	salary_to	experience	city	employment_type
0	37351176	60000.0	70000.0	Нет опыта	Екатеринбург	Удалённая работа
1	53503796	140000.0	210000.0	От 1 года до 3 лет	Москва	Полная занятость
2	20319022	NaN	NaN	Более 6 лет	Москва	Полная занятость
3	40619665	145000.0	215000.0	От 1 года до 3 лет	Нижний Новгород	Полная занятость
4	14675717	NaN	NaN	Более 6 лет	Москва	Полная занятость

Генерация столбца для подсчета зп

```
def calculate_avg_salary(row):
    if pd.notna(row['salary_from']) and pd.notna(row['salary_to']):
        return (row['salary_from'] + row['salary_to']) / 2
    elif pd.notna(row['salary_from']):
        return row['salary_from']
    elif pd.notna(row['salary_to']):
        return row['salary_to']
    else:
        return np.nan

df['salary_avg'] = df.apply(calculate_avg_salary, axis=1)
df_clean = df.dropna(subset=['salary_avg']).copy()
df_clean.head()
```

	vacancy_id	salary_from	salary_to	experience	city	employment_type	salary
0	37351176	60000.0	70000.0	Нет опыта	Екатеринбург	Удалённая работа	65000
1	53503796	140000.0	210000.0	От 1 года до 3 лет	Москва	Полная занятость	17500
3	40619665	145000.0	215000.0	От 1 года до 3 лет	Нижний Новгород	Полная занятость	18000
5	21241867	60000.0	70000.0	Нет опыта	Москва	Стажировка	65000

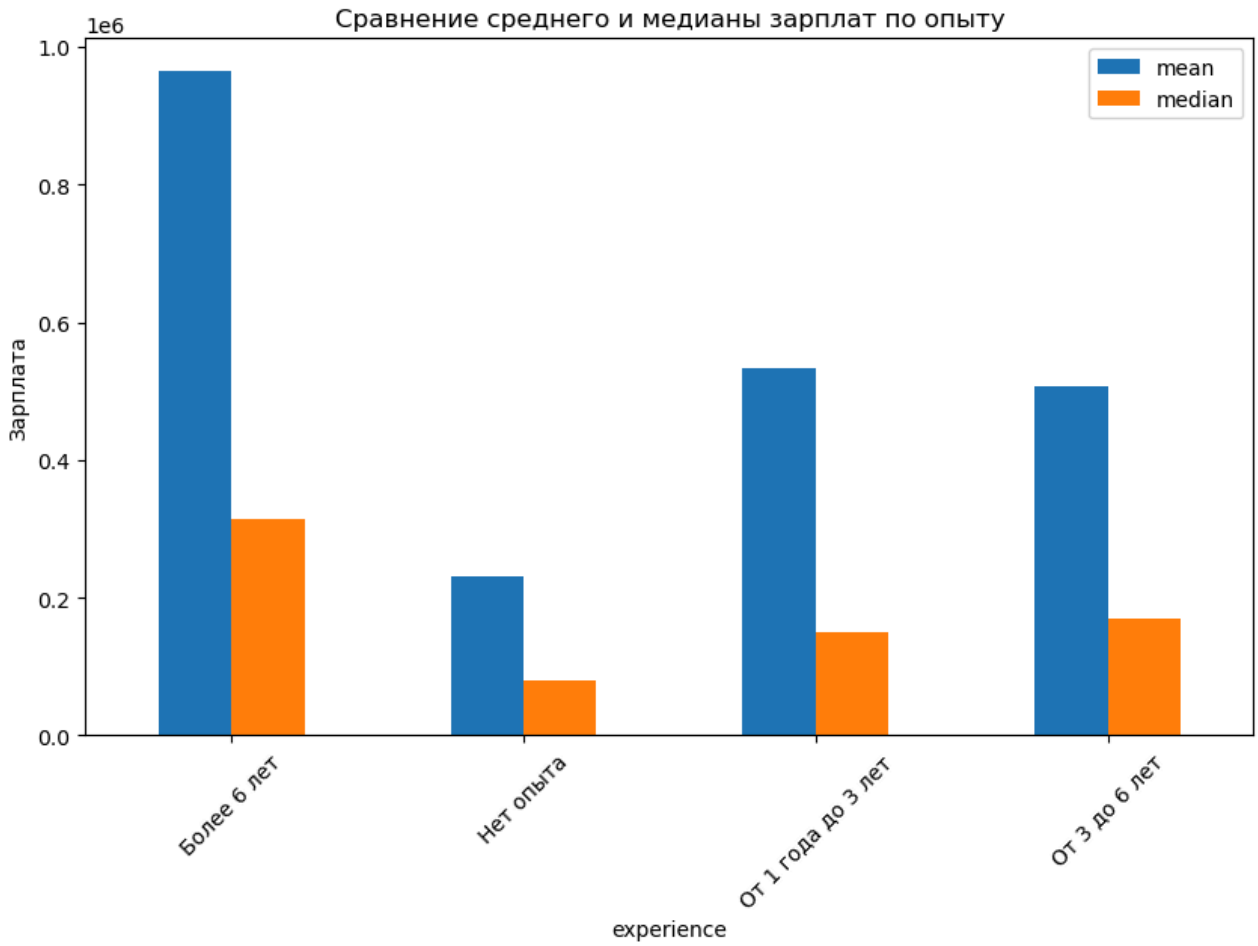
A1

```
stats = df_clean.groupby('experience')['salary_avg'].agg([
    'mean',
    'median',
    'std',
    lambda x: x.quantile(0.25),
    lambda x: x.quantile(0.75)
]).rename(columns={'<lambda_0>': 'Q1_25%', '<lambda_1>': 'Q3_75%'})
display(stats)
```

	mean	median	std	Q1_25%	Q3_75%
experience					
Более 6 лет	963833.820520	315000.0	4.815278e+06	237500.0	402500.0
Нет опыта	231816.852270	80000.0	1.124442e+06	62500.0	95000.0
От 1 года до 3 лет	533135.921615	150000.0	2.880934e+06	110000.0	217500.0
От 3 до 6 лет	506372.460787	170000.0	2.547226e+06	125000.0	225000.0

A2

```
stats[['mean', 'median']].plot(kind='bar', figsize=(10, 6))
plt.title('Сравнение среднего и медианы зарплат по опыту')
plt.ylabel('Зарплата')
plt.xticks(rotation=45)
plt.show()
```

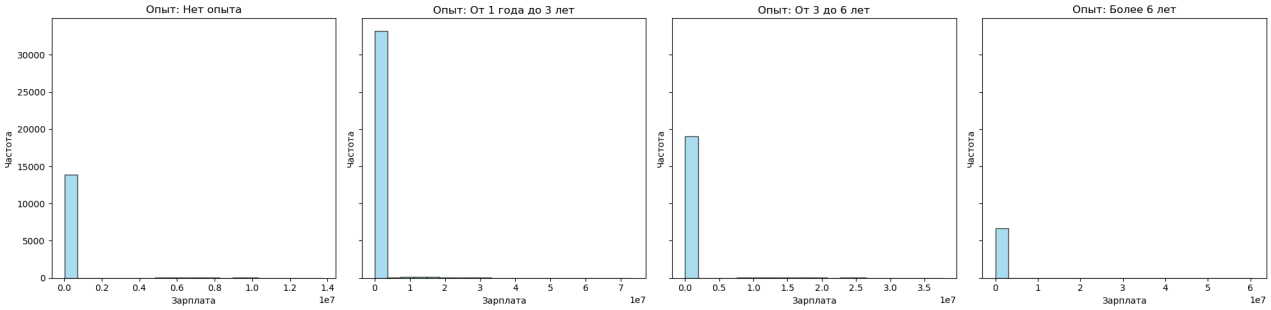

Сравнение среднего и медианы зарплат по опыту
1e6
1.0
0.8
0.6
0.4
0.2
0.0
Зарплата
mean
median
Более 6 лет
Нет опыта
От 1 года до 3 лет
От 3 до 6 лет
experience

A3

```
experiences = df_clean['experience'].unique()
fig, axes = plt.subplots(1, len(experiences), figsize=(20, 5), sharey=True)

for i, exp in enumerate(experiences):
    subset = df_clean[df_clean['experience'] == exp]
    axes[i].hist(subset['salary_avg'], bins=20, alpha=0.7, color='skyblue',
edgecolor='black')
    axes[i].set_title(f'Опыт: {exp}')
    axes[i].set_xlabel('Зарплата')
    axes[i].set_ylabel('Частота')

plt.tight_layout()
plt.show()
```



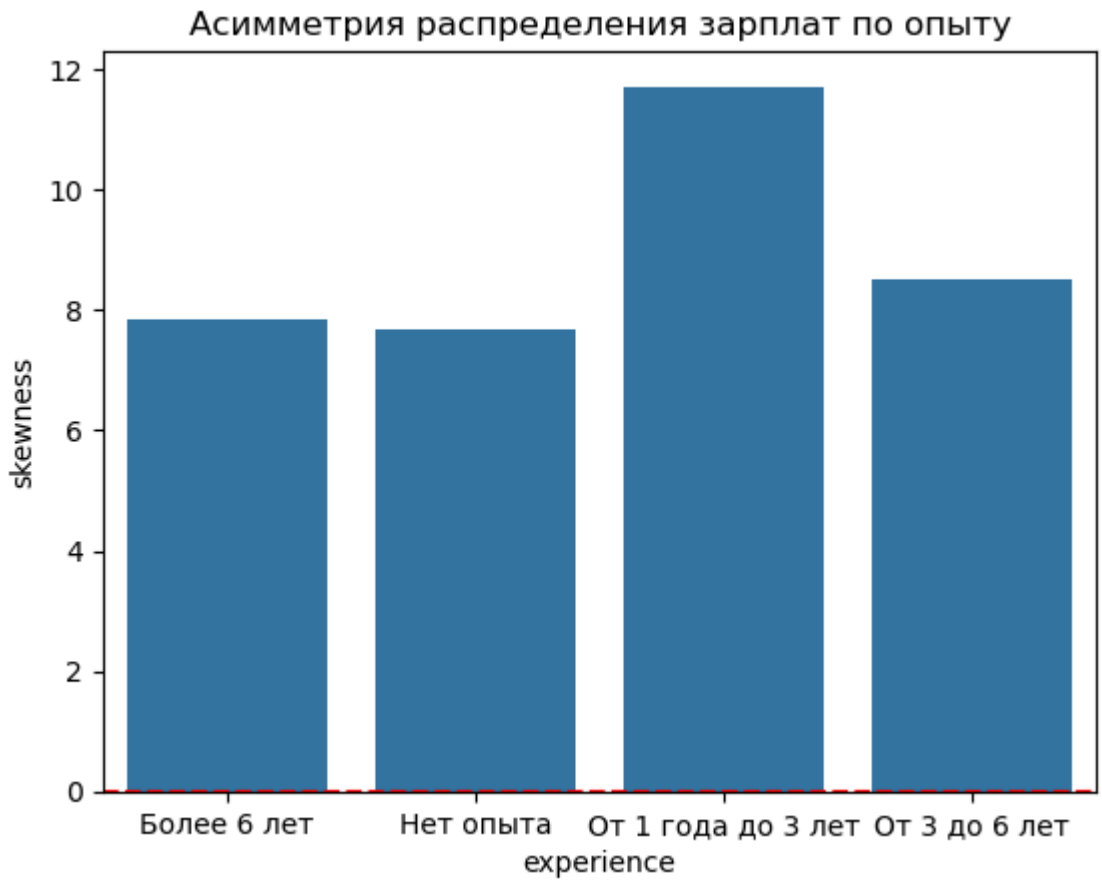
B1

```
skewness = df_clean.groupby('experience')['salary_avg'].apply(skew).reset_index()
skewness.columns = ['experience', 'skewness']

print("B1. Коэффициент асимметрии по группам:")
display(skewness)
sns.barplot(x='experience', y='skewness', data=skewness)
plt.title('Асимметрия распределения зарплат по опыту')
plt.axhline(0, color='red', linestyle='--')
plt.show()
```

```
B1. Коэффициент асимметрии по группам:
```

	experience	skewness
0	Более 6 лет	7.838746
1	Нет опыта	7.689248
2	От 1 года до 3 лет	11.715786
3	От 3 до 6 лет	8.514026



B2

При правосторонней асимметрии (положительный skewness) среднее значение всегда больше медианы. Это происходит потому, что редкие, но очень высокие зарплаты сильно увеличивают сумму, но не влияют на позицию середины списка (медиану). Чем больше разрыв между средним и медианой, тем сильнее асимметрия.

B3

```
std_dev = df_clean.groupby('experience')['salary_avg'].std().apply(lambda x: f"
{x:0.3f}").reset_index()
std_dev.columns = ['experience', 'std_dev']
print("B3. Стандартное отклонение (разброс) по группам:")
display(std_dev)
```

```
B3. Стандартное отклонение (разброс) по группам:
```

	experience	std_dev
0	Более 6 лет	4815278.150
1	Нет опыта	1124442.237
2	От 1 года до 3 лет	2880933.579
3	От 3 до 6 лет	2547225.696

C1

Для описания «типичной» зарплаты лучше использовать медиану.
Как мы выяснили в B1 и B2, распределение зарплат скошено вправо (есть выбросы). Среднее значение сильно завышается этими выбросами и не отражает реальную картину для большинства кандидатов. Медиана устойчива к выбросам и показывает зарплату «среднего» человека в выборке.

C2

Вася должен сделать следующие оговорки:

- Источник данных: Откуда взята цифра N?
- Выборка: Учитывались ли вакансии с неполной занятостью? Только ли IT? Только ли Москва?
- Форма распределения: Является ли N средним арифметическим? Если распределение скошено, среднее может вводить в заблуждение.
- Актуальность: Данные за какой год?

C3

По имеющимся данным мы видим разницу в медианах и средних. Однако, чтобы утверждать это строго, нужно провести статистический тест для проверки гипотезы о равенстве средних/медиан. Визуально разница есть, но она может быть случайной. Также нужно учитывать размер выборки и разброс.

D1

Васе следует использовать медиану для той группы, к которой он относится.
Интерпретация: «Согласно данным рынка, медианная зарплата для специалистов с моим

опытом составляет X рублей. Я ориентируюсь на эту сумму, так как она отражает типичное предложение, исключая крайние выбросы».

D2

Предсказуемость ниже в группах с большим разбросом (обычно это «Более 6 лет» и «От 3 до 6 лет»). Там стандартное отклонение высокое.
Стратегия: Если Вася идет в группу с высоким разбросом, ему нужно быть готовым к тому, что предложения могут сильно отличаться. Стоит активнее торговаться и смотреть на конкретные навыки, а не только на опыт.

Задание 2

A1

Вася пишет: 78% из 200 учеников нашли работу в первый месяц.

Вероятность: P(нашёл работу в первый месяц | ученик автора) = 0.78

Противоположная вероятность: P(не нашёл) = 1 − 0.78 = 0.22 (22%)
В абсолютных числах: 200 × 0.78 = 156 учеников

A2

Вася пишет: «85% получивших оффер указали в резюме SQL и Python».

Событие A: «Получил оффер»

Событие B: «Указал в резюме SQL и Python»

Известная вероятность: Это $P(B|A) = 0.85$ — условная вероятность того, что кандидат указал SQL/Python, при условии, что он уже получил оффер. Это не то же самое, что $P(A|B)$.

A3

Конверсия = 10%, отклики независимы.

P(1 отклик → оффер) = 0.1

P(2 подряд → оба отказ) = 0.9 × 0.9 = 0.81 (81%)

P(5 подряд → все отказы) = 0.9^5 = 0.59049 (≈59%)

B1

Вася делает вывод: «85% получивших оффер указывали SQL/Python ⇒ хочешь оффер, учи SQL/Python».

Известно: P(SQL/Python | Оффер) = 0.85

Нужно для вывода: P(Оффер | SQL/Python)

Это разные вероятности. Чтобы сделать корректный вывод, нужны дополнительные данные: сколько людей без SQL/Python получили оффер и сколько людей с SQL/Python остались без оффера. Без этого вывод - логическая ошибка

B2

Вася опросил 200 своих учеников, получил 78%.

Проблема: Смещение выборки. Опрашиваются только те, кто дошёл до конца курса и ответил на опрос. Те, кто бросил, не нашёл работу или недоволен - скорее всего, в выборку не попали.
Направление смещения: Цифра 78% систематически завышена.

Как организовать сбор данных: Нужен контроль группы или хотя бы отслеживание всех записавшихся, а не только «выживших».

B3

Вася пишет: «Получил 10 отказов подряд? Следующий точно даст оффер».

Нет. Это ошибка игрока.

Скрытое предположение: Автор неявно считает, что отказы «накапливаются» и увеличивают шанс следующего отклика. Это неверно, если отклики независимы.

Реалистичность: В реальности отказы могут быть связаны , поэтому серия отказов - скорее сигнал менять подход, а не ждать удачи.

C1

Вася пишет: «Если конверсия 10%, то после 20 откликов ты гарантированно получишь оффер» Нет.

Правильный расчёт: P(хотя бы 1 оффер за 20 откликов) = $1 - 0.9^{20} \approx 0.8784$ (≈88%). Это не 100%.

Распределение: Биномиальное.

Сколько откликов для 95%?
$1 - 0.9^n \geq 0.95$
$0.9^n \leq 0.05$
$n \geq \ln(0.05) / \ln(0.9) \approx 28.43$
⇒ нужно 29 откликов.

C2

среднее число откликов до оффера - 35.

Форма распределения: Скошено вправо (положительная асимметрия). Большинство находит работу быстрее, но есть «длинный хвост» из тех, кто ищет очень долго.

Медиана vs среднее: Медиана будет меньше среднего (например, 25 против 35).

Вывод для кандидата: Если у тебя 35 откликов и нет оффера - это не аномалия. Ты можешь быть в «длинном хвосте». Но стоит проанализировать, не находишься ли ты в самом его конце.

D1

Факт Ошибка Корректный вывод

Факт 1 / Смещение выборки / 78% — завышено, не отражает реальную эффективность

Факт 2 / $P(B|A) \neq P(A|B)$ / Корреляция ≠ причинность, нужны контрольные данные

Факт 3 / Игнорирование формы распределения / Среднее искажено выбросами, медиана ниже

Факт 4 / Ошибка игрока / 20 откликов → 88%, а не 100%

Факт 5 / Ошибка игрока + независимость / 10 отказов не увеличивают шанс следующего

Этот пост — классический пример статистической безграмотности под красивыми цифрами. Автор путает условные вероятности, игнорирует смещение выборки и пропагандирует ошибку игрока. Не верьте слепо таким советам. Учите SQL и Python, потому что это полезно, а не потому что вам пообещали 100% оффер после 20 откликов.

D2

Сколько откликов в неделю: 10–15. Это даёт ~40–60 откликов в месяц и позволяет собрать статистику, не выгорая.

Как долго в одном режиме: 1 месяц (4 недели). За это время набирается достаточная выборка для оценки конверсии.

Сигналы для коррекции:

0 офферов за 40 откликов ⇒ менять резюме/стратегию.

1–2 оффера ⇒ стратегия работает.

Много офферов ⇒ можно повысить требования.

D3

Предположения: Что конверсия Вовы ≈10% и отклики независимы. Если резюме слабое, конверсия может быть 1–2%.

Когда не сработает: Рынок перенасыщен, или у Вовы нет нужных навыков (SQL/Python).

Дополнительная информация: Данные по конверсии для похожего профиля и фидбек от HR после отказов.